

1. CAPA

Nome do Grupo: NKM

Nomes e RM Integrantes:

- Kauanne Oliveira - 574191
- Matheus Santana - 574166
- Nayhely Estela - 571416

Domínio: Toolkit para Chatbot com IA Generativa

Nome do toolkit: PromptToolKit

2. DOMÍNIO E PROBLEMA

2.1. Por que este domínio?

O projeto foi desenvolvido no domínio de Toolkit para Chatbot com IA Generativa, porque o foco é estudar como diferentes técnicas de prompting influenciam as respostas de modelos de linguagem (LLMs). O toolkit facilita o estudo dessas técnicas, permitindo comparar diferentes estratégias de prompting e analisar o comportamento dos modelos.

2.2. Qual problema real o toolkit resolve?


O PromptToolKit resolve a dificuldade de organizar, testar e avaliar prompts utilizados em chatbots com IA generativa. Sem uma estrutura adequada, os prompts podem se tornar repetitivos, desorganizados e difíceis de manter, além de tornar os testes manuais demorados e pouco eficientes. O toolkit automatiza esse processo ao centralizar prompts, montar mensagens dinamicamente e permitir a comparação entre diferentes técnicas de prompting, avaliando fatores como acurácia, consistência, custo e tempo de execução. Além disso, o sistema gera relatórios e gráficos automaticamente, facilitando a análise dos resultados e ajudando a identificar quais técnicas produzem melhores respostas em diferentes tipos de tarefas.

3. ARQUITETURA

3.1. Link do diagrama

https://drive.google.com/file/d/1Kwb7wmU9ba5GP0HD--fnX8KAWv2sL99r/view?usp=drive_link

3.2. Imagem do diagrama



4. STACK TÉCNICA

4.1. Versões

- *Linguagem*: Python 3.11 ou superior.
- *LLM (Modelo)*: qwen2.5:1.5b executado localmente via Ollama API.

4.2. Lista de bibliotecas principais

- *ollama*: SDK oficial utilizado para comunicação com os modelos locais executados via Ollama.
- *pandas*: Responsável pela manipulação de dados, criação do DataFrame de resultados e exportação para CSV.
- *matplotlib*: Utilizada para a geração de gráficos comparativos de acurácia, custo, temperatura e tempo de execução.
- *python-dotenv*: Responsável por carregar as configurações de variáveis de ambiente a partir do arquivo `.env`.

4.3. Instruções para execução

4.3.1. Configuração do Ollama

- Certifique-se de que o Ollama está instalado e em execução no computador.
- Baixe o modelo utilizado pelo projeto: `ollama pull qwen2.5:1.5b`
- Inicie o serviço do Ollama: `ollama serve`

OBS.: Certifique-se de que o serviço do Ollama esteja acessível no host configurado no `.env`.

4.3.2. Preparação do Ambiente Python

- Clone o repositório e, dentro da pasta raiz, crie e ative um ambiente virtual (`venv`) para isolar as dependências:

```
# Criar ambiente virtual
```

```
python -m venv venv
```

```
# Ativar (Windows)
```

```
.\venv\Scripts\activate
```

```
# Ativar (Linux/Mac)
```

```
source venv/bin/activate
```

4.3.3. Instalação de Dependências

- Instale todas as bibliotecas necessárias listadas no arquivo `requirements.txt`: `pip install -r requirements.txt`

4.3.4. Configuração das Variáveis de Ambiente

- Localize o arquivo `.env.example` na raiz do projeto, crie uma cópia e renomeie para `.env`.
- Edite o arquivo com as configurações da API local:

OLLAMA_HOST=<http://localhost:11434>

MODEL_NAME=qwen2.5:1.5b

4.3.5. Execução do Toolkit

- O ponto de entrada principal do sistema é o arquivo `main.py`.
- Para iniciar o processo de carregamento de inputs, aplicação das técnicas de prompting e geração de relatórios, execute:
`python main.py`

4.3.6. O sistema executará automaticamente as técnicas

- Zero-Shot Prompting
- Few-Shot Prompting
- Chain-of-Thought (CoT)
- Role Prompting

4.3.7. Verificação de Resultados

Após a execução, os artefatos serão gerados automaticamente:

- Tabela Comparativa
 - Salva em: `output/resultados.csv`
- Gráficos
 - Arquivos PNG salvos na pasta: `output/graficos/`
 - Gráficos gerados:
 - `acuracia.png`
 - `custo.png`
 - `temperatura.png`
 - `tempo_execucao.png`


5. RESULTADOS

5.1. Tabela comparativa


tarafa	tipo	tecnica	input	esperado	resposta	tokens_prompt	tempo_ms	acuracia
classificacao_fee...	classificacao	Zero-Shot	Os professores são...	POSITIVO	POSITIVO	97	8833.78	1
classificacao_fee...	classificacao	Few-Shot	Os professores são...	POSITIVO	POSITIVO	144	7813.17	1
classificacao_fee...	classificacao	Chain-of-Thought	Os professores são...	POSITIVO	POSITIVO	105	4481.87	1
classificacao_fee...	classificacao	Role Prompting	Os professores são...	POSITIVO	POSITIVO	97	7838.34	1
classificacao_fee...	classificacao	Zero-Shot	As videoaulas são...	NEGATIVO	NEGATIVO	91	6143.9	1
classificacao_fee...	classificacao	Few-Shot	As videoaulas são...	NEGATIVO	NEGATIVO	138	7871.17	1
classificacao_fee...	classificacao	Chain-of-Thought	As videoaulas são...	NEGATIVO	NEGATIVO	99	6779.03	1
classificacao_fee...	classificacao	Role Prompting	As videoaulas são...	NEGATIVO	NEGATIVO	91	7889.33	1
classificacao_fee...	classificacao	Zero-Shot	Gostei do conteúdo...	MISTO	NEGATIVO	97	6494.71	0
classificacao_fee...	classificacao	Few-Shot	Gostei do conteúdo...	MISTO	POSITIVO	144	8872.81	0
classificacao_fee...	classificacao	Chain-of-Thought	Gostei do conteúdo...	MISTO	NEGATIVO	105	6456.73	0
classificacao_fee...	classificacao	Role Prompting	Gostei do conteúdo...	MISTO	NEGATIVO	97	8239.9	0
classificacao_fee...	classificacao	Zero-Shot	Ainda estou utili...	NEUTRO	NEGATIVO	97	6281.37	0
classificacao_fee...	classificacao	Few-Shot	Ainda estou utili...	NEUTRO	NEUTRO	144	8124.1	1
classificacao_fee...	classificacao	Chain-of-Thought	Ainda estou utili...	NEUTRO	NEGATIVO	105	6869.91	0
classificacao_fee...	classificacao	Role Prompting	Ainda estou utili...	NEUTRO	NEUTRO	97	7188.7	1
classificacao_fee...	classificacao	Zero-Shot	A didática do curso foi excelente.	POSITIVO	POSITIVO	88	5673.78	1
classificacao_fee...	classificacao	Few-Shot	A didática do curso...	POSITIVO	POSITIVO	135	6981.04	1
classificacao_fee...	classificacao	Chain-of-Thought	A didática do curso...	POSITIVO	POSITIVO	96	5817.11	1
classificacao_fee...	classificacao	Role Prompting	A didática do curso...	POSITIVO	POSITIVO	88	7881.36	1
extracao_informac...	extracao	Zero-Shot	Curso de Machine L...	''''jsonde	''''cu...	79	7414.79	0
extracao_informac...	extracao	Few-Shot	Curso de Machine L...	''''jsonde	''''cu...	124	8689.6	0
extracao_informac...	extracao	Chain-of-Thought	Curso de Machine L...	''''jsonde	''''cu...	87	14375.21	0
extracao_informac...	extracao	Role Prompting	Curso de Machine L...	''''jsonde	''''cu...	79	10532.68	0
extracao_informac...	extracao	Zero-Shot	Curso de Banco de...	{p "curso": {p ...	{p ...	81	8167.05	0

5.2. Gráficos gerados pelo sistema


5.2.1. Acurácia Média por Técnica




5.2.2. Custo Médio de Tokens



5.2.3. Consistência por Temperatura



5.2.4. Tempo Médio de Execução



6. GUIA DE BOLSO

6.1. Guia de Bolso - Quando Usar Cada Técnica de Prompting

6.1.1. Tabela — Quando Usar Cada Técnica

Técnica	Quando usar	Principal vantagem	Limitação	Exemplo
Zero-Shot Prompting	Tarefas simples e diretas	Baixo custo e rapidez	Menor consistência em tarefas complexas	Classificação simples ou resumo curto
Few-Shot Prompting	Quando a saída precisa seguir um padrão	Maior consistência nas respostas	Maior consumo de tokens	Extração estruturada ou respostas padronizadas
Chain-of-Thought (CoT)	Problemas que exigem raciocínio passo a passo	Melhor desempenho em tarefas complexas	Respostas mais longas	Matemática, lógica e análise
Role Prompting	Quando o modelo precisa	Respostas mais contextualizadas	Pode gerar excesso de formalidade	“Você é um analista de dados...”

Técnica	Quando usar	Principal vantagem	Limitação	Exemplo
	assumir um papel específico			

6.1.2. Comparativo Geral

Critério	Zero-Shot	Few-Shot	CoT	Role Prompting
Velocidade	Alta	Média	Baixa	Média
Consumo de Tokens	Baixo	Médio	Alto	Médio
Precisão em tarefas complexas	Média	Boa	Muito Alta	Alta
Contextualização	Baixa	Média	Média	Alta

6.1.3. Recomendações para o Projeto

- **Zero-Shot:** ideal para benchmarks rápidos e tarefas simples.
- **Few-Shot:** recomendado quando é necessário padronizar respostas.
- **CoT:** melhor escolha para análises, lógica e raciocínio complexo.
- **Role Prompting:** útil para respostas técnicas e especializadas.

6.1.4. Conclusão

Cada técnica possui vantagens específicas dependendo do objetivo da tarefa: Zero-Shot prioriza velocidade e simplicidade, enquanto Few-Shot melhora consistência; Chain-of-Thought melhora raciocínio e Role Prompting melhora contextualização.

Em uma análise objetiva, a escolha correta da técnica impacta diretamente: qualidade das respostas; custo computacional; consumo de tokens; tempo de execução; interpretabilidade dos resultados.

Por isso, selecionar adequadamente a estratégia de prompting é fundamental para maximizar o desempenho do toolkit.

7. REFLEXÃO

7.1. O que mais surpreendeu durante o desenvolvimento

Um dos pontos que mais chamou atenção foi perceber que técnicas consideradas “mais avançadas” nem sempre apresentaram os melhores resultados gerais. A expectativa inicial era de que o Chain-of-Thought tivesse o maior desempenho em praticamente todos os cenários, já que utiliza raciocínio passo a passo. Porém, os resultados mostraram que isso nem sempre significa maior acurácia ou eficiência.

Também foi surpreendente observar como pequenas mudanças na forma do prompt impactaram diretamente: a precisão das respostas; o tempo de execução; o consumo de tokens e a consistência do modelo.

Outro ponto interessante foi perceber o efeito da temperatura na estabilidade das respostas. Os testes mostraram que temperaturas menores geraram resultados mais consistentes, enquanto valores maiores aumentaram a variação das respostas produzidas pelo modelo.

Além disso, a experiência mostrou que modelos locais conseguem executar tarefas relevantes de NLP mesmo sem infraestrutura extremamente complexa, o que tornou o projeto mais interessante do ponto de vista prático.

7.2. Qual técnica apresentou melhor resultado

Com base nos gráficos gerados, a técnica que apresentou o melhor equilíbrio geral foi o **Few-Shot Prompting**. Visto que obteve a maior acurácia média entre as técnicas avaliadas; uma boa consistência nas respostas e um desempenho superior em tarefas que exigiam padronização.

Apesar de possuir maior custo de tokens, o ganho em precisão compensou esse aumento, principalmente em tarefas de classificação e extração estruturada.

7.3. O que poderia ser feito diferente em uma próxima versão

Após os experimentos, algumas melhorias ficaram evidentes para versões futuras do projeto. A principal seria ampliar a quantidade e diversidade dos datasets utilizados, permitindo análises mais robustas e reduzindo possíveis vieses causados pelo pequeno conjunto de testes.

Também seria interessante testar mais modelos locais diferentes; realizar comparações de resultados com APIs comerciais; adicionar métricas mais detalhadas de avaliação; automatizar melhor os relatórios e análises estatísticas.

Outra melhoria importante seria realizar um ajuste mais refinado dos prompts, principalmente nas técnicas Few-Shot e Role Prompting, buscando exemplos mais representativos e especializados para cada tarefa.

Além disso, seria interessante explorar combinações entre técnicas, como: Role Prompting + Chain-of-Thought e Few-Shot + CoT. Os resultados sugerem que abordagens híbridas podem gerar respostas mais consistentes e precisas do que o uso isolado de apenas uma técnica.